Минобрнауки России
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Волгоградский государственный технический университет»

Факультет Электроники и вычислительной техники

Кафедра Электронно-вычислительные машины и системы

# ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
## к курсовой работе (проекту)

по дисциплине Системы обработки больших данных

на тему: Исследование датасета отзывов сотрудников о работодателях с использованием фреймворка Apache Spark

Студент Орлов Артём Андреевич
(фамилия, имя, отчество)

Группа САПР-1.3

Руководитель работы (проекта) _____ П.Д. Кравченя
(подпись и дата подписания) (инициалы и фамилия)

Члены комиссии:

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

_____ _____
(подпись и дата подписания) (инициалы и фамилия)

Нормоконтроллер _____ П.Д. Кравченя
(подпись и дата подписания) (инициалы и фамилия)

Волгоград 2026

Минобрнауки России
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Волгоградский государственный технический университет»

Факультет Электроники и вычислительной техники

Направление (специальность) Информатика и вычислительная техника

Кафедра Электронно-вычислительные машины и системы

Дисциплина Системы обработки больших данных

Утверждаю
Зав. кафедрой А.Е. Андреев

«____» _____ 20 ____ г.

# ЗАДАНИЕ
## на курсовую работу (проект)

Студент Орлов Артём Андреевич
(фамилия, имя, отчество)

Группа САПР-1.3

1. Тема: Исследование датасета отзывов сотрудников о работодателях с использованием фреймворка Apache Spark

Утверждена приказом от «___» _____ 20 ___ г., № _____.

2. Срок представления работы (проекта) к защите «___» _____ 20 ___ г.

3. Содержание расчётно-пояснительной записки: РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ PYSPARK.

4. Перечень графического материала:

5. Дата выдачи задания «___» _____ 20 ___ г.

Руководитель работы (проекта) _____ П.Д. Кравченя
(подпись и дата подписания) (инициалы и фамилия)

Задание принял к исполнению _____ А.А. Орлов
(подпись и дата подписания) (инициалы и фамилия)

СОДЕРЖАНИЕ

ВВЕДЕНИЕ . . . . . 4
1 РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ PYSPARK . . . . . 5
1.1 Постановка задачи разведочного анализа . . . . . 5
1.2 Описание датасета . . . . . 6
1.3 Определение типов признаков . . . . . 7
1.4 Поиск и удаление дубликатов . . . . . 8
1.5 Определение и устранение пропущенных значений . . . . . 9
1.6 Выявление и устранение выбросов . . . . . 11
1.7 Статистические показатели признаков . . . . . 14
1.8 Визуализация распределений наиболее важных признаков . . . 16
1.9 Корреляционный анализ . . . . . 18
1.10 Выводы . . . . . 22
ЗАКЛЮЧЕНИЕ . . . . . 24
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ . . . . . 25

# ВВЕДЕНИЕ

# 1 РАЗВЕДОЧНЫЙ АНАЛИЗ ДАННЫХ С ИСПОЛЬЗОВАНИЕМ PYSPARK

## 1.1 Постановка задачи разведочного анализа

Разведочный анализ данных (exploratory data analysis, EDA) — этап исследования, на котором данные изучаются до построения моделей. На этом этапе определяются состав и качество данных, выявляются пропуски, ошибки и аномальные значения, оцениваются распределения признаков и взаимосвязи между ними [1].

Исходными данными является датасет отзывов сотрудников о работодателях объёмом около 3,8 ГБ, содержащий почти 10 млн записей и размещённый в распределённой файловой системе HDFS кластера Apache Hadoop. При таком объёме обработка средствами одного компьютера неэффективна, поэтому вычисления выполняются фреймворком Apache Spark [2; 3], задания которого распределяются по узлам кластера менеджером ресурсов YARN [4]. Требуется средствами DataFrame API библиотеки PySpark:

1. определить типы признаков датасета;
2. выявить пропущенные значения и устранить их;
3. выявить выбросы и устранить их;
4. рассчитать статистические показатели признаков (средние, среднеквадратичные отклонения, квартили и т. д.);
5. визуализировать распределения наиболее важных признаков;
6. рассчитать корреляции между признаками.

Кроме того, необходимо загрузить исходный файл, привести признаки к корректным типам и сохранить результаты обработки в таблицы формата Apache Iceberg.

Анализ выполнялся на кластере с использованием Apache Spark и Apache Iceberg. Драйвер работал в Jupyter-ноутбуке на узле кластера. Все операции над полными данными (фильтрация, группировка, агрегирование) выполнялись в

Spark, а в библиотеку pandas передавались только агрегированные результаты небольшого объёма, необходимые для построения графиков [5; 6].

## 1.2 Описание датасета

Для исследования выбран датасет Glassdoor Job Reviews 2 [7], размещённый на платформе Kaggle по адресу `https://www.kaggle.com/datasets/davidgauthier/glassdoor-job-reviews-2`. Он содержит отзывы сотрудников о компаниях-работодателях, опубликованные на сайте Glassdoor, где текущие и бывшие сотрудники анонимно оценивают условия работы. Датасет распространяется по лицензии CC BY-NC-SA 4.0, допускающей учебное использование. В работе использована версия 3 от 15 октября 2024 года. Датасет состоит из файла `all_reviews.csv` объёмом 3,8 ГБ с 19 столбцами и содержит 9 901 889 записей о 34 374 компаниях за период с 25 января 2008 года по 26 июля 2023 года.

Каждая запись соответствует одному отзыву и включает общую оценку работодателя по шкале от 1 до 5, оценки по шести отдельным критериям (далее — подоценки), мнение автора о компании, её генеральном директоре и перспективах, сведения об авторе и четыре текстовых поля. Мнения закодированы буквами: `v` — положительное, `r` — нейтральное, `x` — отрицательное, `o` — нет мнения. Используемые признаки перечислены в таблице 1. Исходные названия столбцов содержат пробелы и символы `/` и `&`, неудобные в SQL-запросах, поэтому при загрузке столбцы были переименованы в стиле snake_case.

При подготовке данных пустые строки заменены на `NULL`, а у значений удалены крайние пробелы. Из ссылки `firm_link` регулярным выражением извлечено название компании (`Reviews/Calgary-Flames-Reviews-E5247.htm` → Calgary Flames). Даты вида «Nov 19, 2022» разобраны по шаблону `MMM d, yyyy`, оценки приведены к числовым типам, а коды мнений заменены категориями Positive, Mild, Negative и No opinion. Из строки статуса («Current Employee, more than 3 years») извлечены признаки

Таблица 1 – Признаки датасета, используемые в работе

| Столбец в файле | Новое название | Описание |
|---|---|---|
| rating | overall_rating | Общая оценка работодателя (1–5) |
| title | headline | Заголовок отзыва |
| status | current | Статус и стаж автора |
| pros, cons | pros, cons | Тексты «плюсы» и «минусы» |
| advice | advice | Совет руководству |
| Recommend | recommend | Рекомендует ли автор компанию |
| CEO Approval | ceo_approv | Одобряет ли генерального директора |
| Business Outlook | outlook | Оценка перспектив компании |
| Career Opportunities | career_opp | Карьерные возможности (1–5) |
| Compensation and Benefits | comp_benefits | Зарплата и льготы (1–5) |
| Senior Management | senior_mgmt | Высшее руководство (1–5) |
| Work/Life Balance | work_life_balance | Баланс работы и жизни (1–5) |
| Culture & Values | culture_values | Культура и ценности (1–5) |
| Diversity & Inclusion | diversity_inclusion | Разнообразие и инклюзивность (1–5) |
| firm_link | firm | Ссылка на страницу компании |
| date | date_review | Дата публикации отзыва |
| job | job_title | Должность автора |

`employee_status` (Current или Former) и `tenure_years` — нижняя граница стажа в годах. Для текстовых полей вычислена длина в словах, после чего сами тексты, занимающие бóльшую часть объёма, удалены. Результат сохранён в таблицу `glassdoor_reviews` формата Apache Iceberg [8] — открытого табличного формата архитектуры LakeHouse [9], хранящего данные в файлах Parquet вместе с метаданными таблицы.

### 1.3 Определение типов признаков

Во второй части работы таблица `glassdoor_reviews` читается из каталога Iceberg и кэшируется в памяти исполнителей методом `cache`, поскольку используется многократно. Для каждого признака определены тип данных и приближённое число уникальных значений. Подсчёт выполнен функцией на алгоритме HyperLogLog++ [10]. В отличие от точного подсчёта, требующего перемешивания всех данных, она работает за один проход с погрешностью около

5 %. Например, для признака `firm` получена оценка 33 128 при точном значении 34 374, то есть погрешность составила 3,6 %. Типы признаков приведены в таблице 2.

Таблица 2 – Типы признаков датасета

| Признак | Тип признака | Уникальных (≈) |
|---|---|---|
| firm | категориальный номинальный | 33 128 |
| job_title | категориальный номинальный | 458 094 |
| date_review | дата | 5 447 |
| employee_status | бинарный категориальный | 2 |
| recommend, ceo_approv, outlook | категориальные порядковые | 3; 4; 4 |
| overall_rating, подоценки | порядковые (шкала 1–5) | 5 |
| tenure_years | количественный дискретный | 6 |
| headline_words, pros_words, cons_words, advice_words | количественные дискретные | 87; 778; 1 399; 9 |

Оценки по шкале 1–5 являются порядковыми признаками, однако при расчёте средних, квартилей и корреляций они, как принято в подобных исследованиях, рассматриваются как количественные дискретные. Мнения упорядочены как Negative < Mild < Positive и имеют дополнительную категорию No opinion. Столбец `current` полностью описывается производными признаками `employee_status` и `tenure_years`, поэтому удалён. В ходе анализа получены также количественный признак `year` (год отзыва) и порядковый признак `tenure_group` (интервал стажа).

### 1.4 Поиск и удаление дубликатов

Уникального ключа отзыва в датасете нет, поэтому дубликатами считались строки, совпадающие по всем признакам. Группировка по всем столбцам выявила 609 412 групп повторяющихся строк, например, набор отзывов об одной компании повторён в файле 2 426 раз. Дубликаты удалены методом `dropDuplicates`, а именно удалено 846 660 строк (8,55 %), осталось 9 055 229. Поиск одинаковых строк требует перемешивания данных, поэтому

результат был закэширован, а прежний кэш освобождён методом `unpersist`. Ограничение метода состоит в том, что вместо самих текстов сравнивалась их длина в словах, поэтому изредка два похожих коротких отзыва могли быть приняты за один. При группах из тысяч одинаковых строк это не меняет вывода: большая часть удалённых строк — настоящие дубликаты.

## 1.5 Определение и устранение пропущенных значений

Для подсчёта пропусков создана функция `null_report`, передающая в один вызов `agg` агрегаты для всех столбцов. Все агрегаты входят в один запрос, поэтому Spark подсчитывает пропуски во всех столбцах одним заданием, за один проход по данным. Результат показан на рисунке 1.

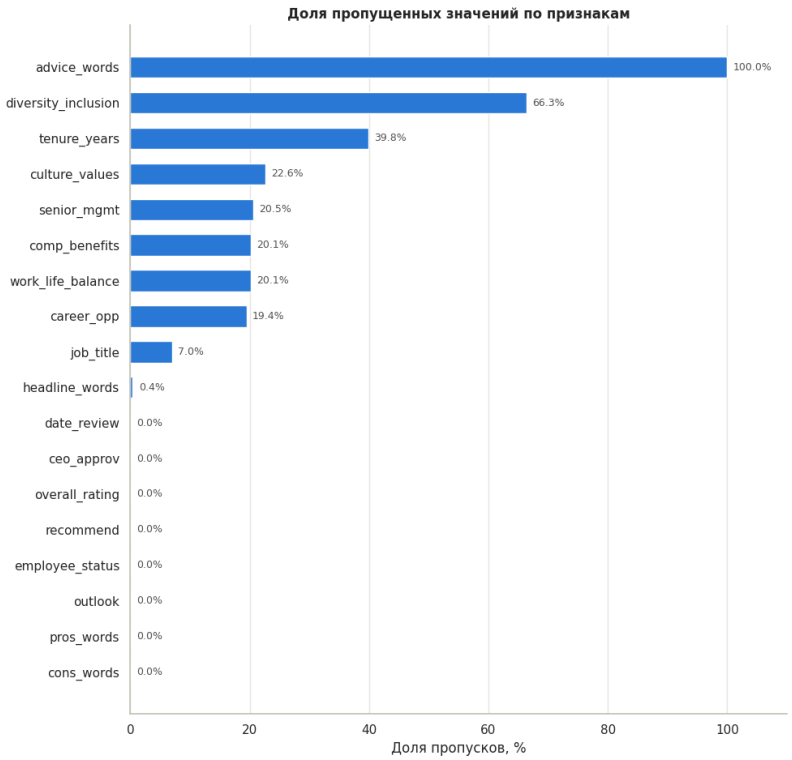



Рисунок 1 – Доля пропущенных значений по признакам

Пропуски распределены неравномерно, и их причины различны. Совет руководству (`advice_words`) заполнен лишь в 13 отзывах, то есть в этой версии датасета поле фактически не собрано. Подоценка `diversity_inclusion` отсутствует в 66,3 % отзывов, так как Glassdoor ввёл её лишь осенью 2020 года [11], поэтому у более ранних отзывов её, как

правило, нет. Это пример неслучайных пропусков. Стаж не указан в 39,8 % отзывов, остальные подоценки пропущены в 19,4–22,6 %, должность — в 7 %. Кроме того, в 145 строках одновременно отсутствуют дата, общая оценка и все мнения — это повреждённые записи.

Пропуски обрабатывались по следующим правилам:

1. строки без ключевых признаков (компания, дата, общая оценка) удаляются;
2. в категориальных признаках пропуски заменяются категорией Unknown;
3. количественный признак с долей пропусков более 50 % удаляется, поскольку заполнение большей части значений исказило бы его распределение;
4. в остальных количественных признаках пропуски заменяются медианой, которая, в отличие от среднего, устойчива к перекосам распределения и всегда является допустимым значением шкалы;
5. пропуск в длине текста означает, что текст не написан, и заменяется нулём.

Медиана вычисляется методом `approxQuantile`, реализующим вариант алгоритма Гринвальда–Ханны [12], который находит квантиль с заданной погрешностью без полной сортировки данных. В результате удалены 145 повреждённых строк, после чего пропуски в общей оценке и мнениях исчезли, а в датасете осталось 9 055 084 строки. Подоценка `diversity_inclusion` удалена. Пропуски в подоценках `work_life_balance` и `culture_values` заполнены медианой 4, в `career_opp`, `comp_benefits` и `senior_mgmt` — медианой 3. Влияние заполнения на распределения показано на рисунке 2.

Заполнение увеличивает долю медианного значения до 38–41 % и уменьшает разброс признаков — известный недостаток заполнения константой. Заполнение подоценки общей оценкой того же отзыва дало бы более правдоподобные значения, но искусственно усилило бы их взаимосвязь, поэтому выбран более нейтральный вариант. Пропуски в `tenure_years` заполнены ме-

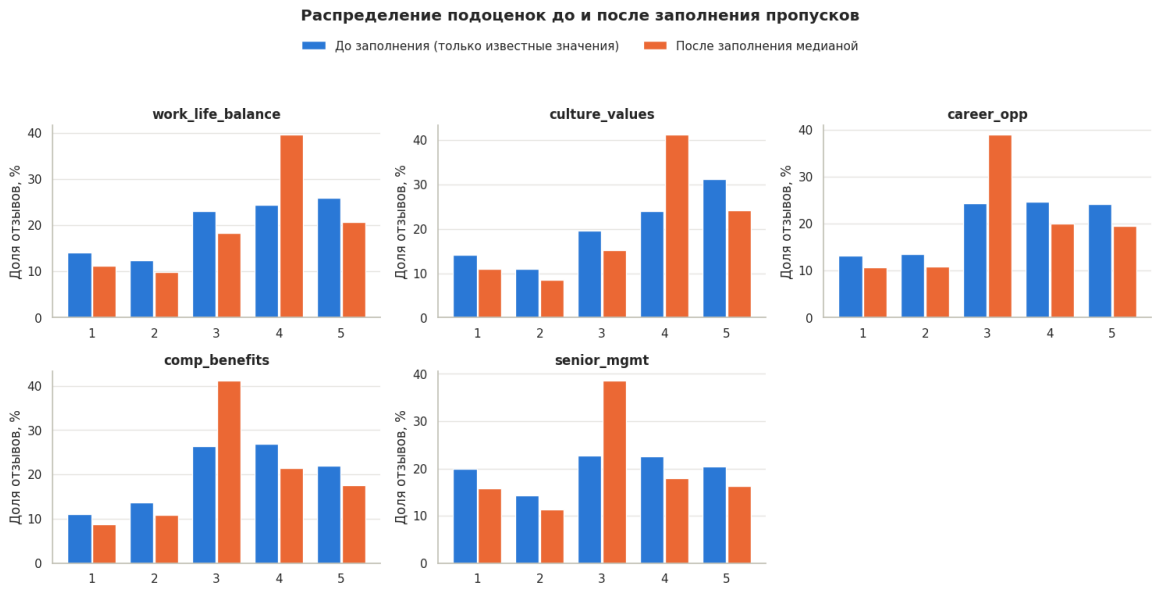



Рисунок 2 – Распределения подоценок до и после заполнения пропусков медианой

дианой, равной одному году. Чтобы сохранить сведения о неуказанном стаже, предварительно создан признак `tenure_group` с отдельной категорией Unknown. Должность скрыта значением Anonymous Employee в 1 567 716 отзывах; по сути это тоже пропуск, поэтому такие значения вместе с пустыми (всего 24,26 %) заменены на Unknown. После замены пропусков нулями признак `advice_words` стал константой, неинформативной для анализа. Итоговая проверка показала, что пропусков в данных не осталось.

### 1.6 Выявление и устранение выбросов

Для поиска выбросов использован метод межквартильного размаха (IQR), лежащий в основе диаграммы «ящик с усами» [1]. Выбросом считается значение, выходящее за границы

$$L = Q_1 - 1{,}5 \cdot IQR, \quad U = Q_3 + 1{,}5 \cdot IQR, \quad IQR = Q_3 - Q_1, \tag{1}$$

где $Q_1$ и $Q_3$ — первый и третий квартили.

**Оценки.** Все значения оценок лежат в пределах шкалы 1–5. Для общей оценки $Q_1 = 3$, $Q_3 = 5$, и по формуле (1) границы равны 0 и 8, так что выбросов нет. Результаты для подоценок приведены в таблице 3 и на рисунке 3.

Таблица 3 – Границы выбросов подоценок по методу IQR

| Подоценка | $Q_1$ | Медиана | $Q_3$ | $L$ | $U$ | Выбросов, % |
|---|---|---|---|---|---|---|
| work_life_balance | 3 | 4 | 4 | 1,5 | 5,5 | 11,26 |
| culture_values | 3 | 4 | 4 | 1,5 | 5,5 | 10,91 |
| career_opp | 3 | 3 | 4 | 1,5 | 5,5 | 10,64 |
| comp_benefits | 3 | 3 | 4 | 1,5 | 5,5 | 8,78 |
| senior_mgmt | 2 | 3 | 4 | $-1$ | 7 | 0,00 |

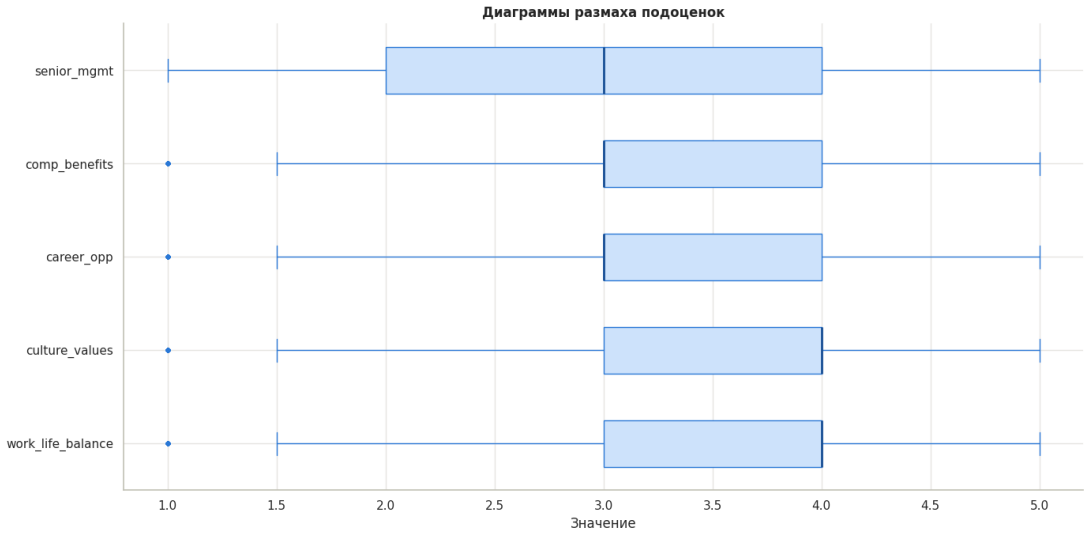



Рисунок 3 – Диаграммы размаха подоценок после заполнения пропусков

У четырёх подоценок межквартильный размах равен единице, и к выбросам формально относятся все оценки 1 — около миллиона строк для каждой подоценки. Отчасти это следствие заполнения медианой, сблизившего квартили. Однако оценка 1 — допустимое значение шкалы, выражающее крайнее недовольство, а не ошибка, поэтому такие строки не удалялись. Этот пример показывает, что правило IQR нельзя механически применять к порядковым шкалам с малым числом значений.

**Число отзывов на компанию.** На одну компанию в среднем приходится 263,4 отзыва при среднеквадратичном отклонении 1 947,9, однако медиана равна 8, а квартили — 2 и 53. Максимум, 134 603 отзыва, принадлежит компании Amazon (рисунок 4). По формуле (1) выбросами являются все компании,

у которых больше 130 отзывов. Однако это не ошибки, а крупные работодатели, поэтому их отзывы сохранены. Следует лишь учитывать, что агрегированные показатели во многом отражают мнение сотрудников крупных компаний. Неравномерность ключа влияет и на производительность Spark: при группировке по `firm` все строки крупной компании попадают в один раздел, и обрабатывающая его задача выполняется дольше остальных (перекос данных, data skew).

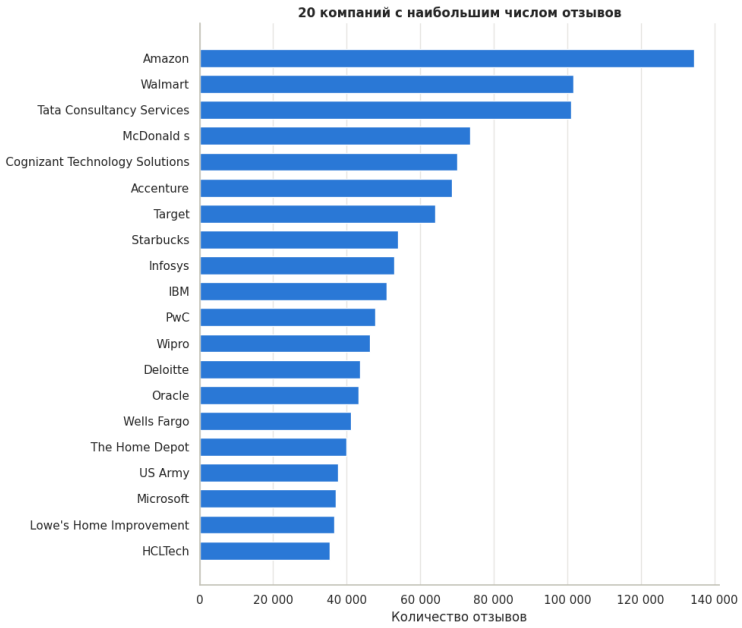



Рисунок 4 – Двадцать компаний с наибольшим числом отзывов

**Длина текстов.** Распределения длин текстов имеют длинный правый хвост (рисунок 5). Медиана длины «плюсов» составляет 8 слов при максимуме 3 153, «минусов» — 9 при максимуме 7 019, заголовка — 3 при максимуме 328. По правилу IQR выбросами являются 5,50 % заголовков, 10,11 % «плюсов» и 10,95 % «минусов», то есть каждый десятый обычный отзыв, поэтому для распределения с длинным хвостом это правило слишком строгое.

Вместо удаления строк применена винзоризация: значения выше 99-го перцентиля заменены самим перцентилем. Границы составили 16 слов для заголовка, 87 — для «плюсов» и 182 — для «минусов»; изменено около 1 % значений каждого признака (от 79 до 99 тыс.). Строки не удалялись, а среднеквадратичное отклонение длины «минусов» снизилось с 41,6 до 28,8 слова. Распределение длины «плюсов» после обработки показано на рисунке 6.

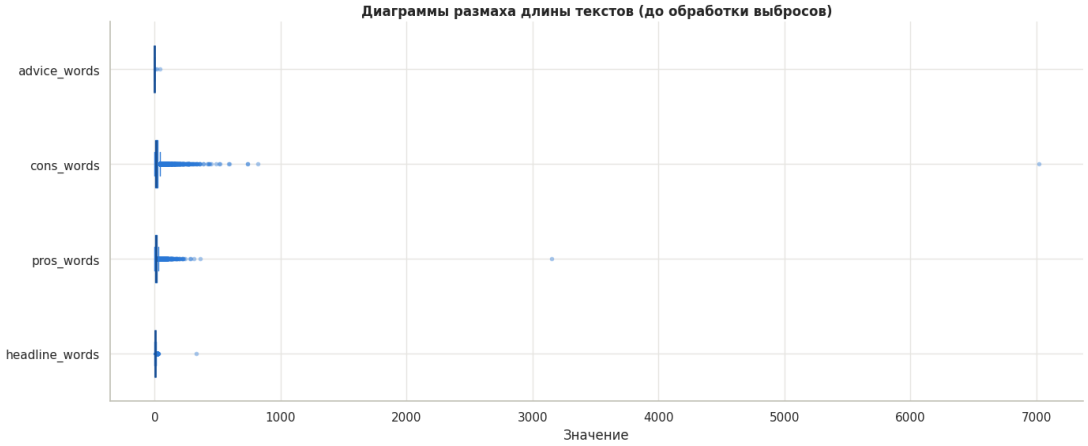



Рисунок 5 – Диаграммы размаха длины текстов до обработки выбросов

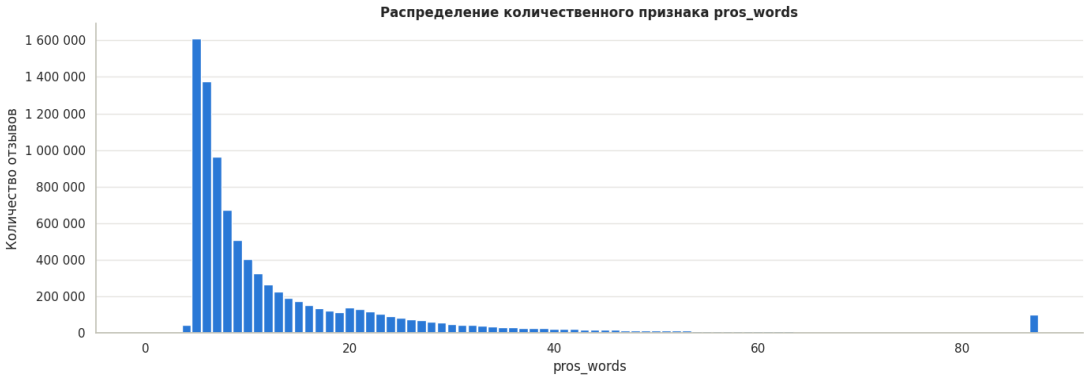



Рисунок 6 – Распределение длины текста «плюсы» после ограничения 99-м перцентилем

Тексты короче пяти слов практически отсутствуют, а самое частое значение равно ровно пяти словам. Вероятно, форма отзыва на сайте требует минимальной длины этого поля. Столбец у правой границы гистограммы образуют значения, ограниченные 99-м перцентилем.

### 1.7 Статистические показатели признаков

В данной работе были рассчитаны статистические показатели количественных признаков за один проход по данным. Результаты приведены в таблице 4.

Средняя общая оценка составляет 3,55 при медиане 4, то есть распределение смещено к высоким оценкам. Выше всех подоценок оценена корпоративная культура (3,59), за ней следуют баланс работы и жизни (3,49), зарплата и льготы (3,28) и карьерные возможности (3,27). Ниже всех оценено высшее руководство

Таблица 4 – Статистические показатели количественных признаков

| Признак | Среднее | СКО | Мин. | $Q_1$ | Медиана | $Q_3$ | Макс. |
|---|---|---|---|---|---|---|---|
| overall_rating | 3,55 | 1,25 | 1 | 3 | 4 | 5 | 5 |
| work_life_balance | 3,49 | 1,24 | 1 | 3 | 4 | 4 | 5 |
| culture_values | 3,59 | 1,24 | 1 | 3 | 4 | 4 | 5 |
| career_opp | 3,27 | 1,20 | 1 | 3 | 3 | 4 | 5 |
| comp_benefits | 3,28 | 1,14 | 1 | 3 | 3 | 4 | 5 |
| senior_mgmt | 3,07 | 1,25 | 1 | 2 | 3 | 4 | 5 |
| tenure_years | 2,10 | 2,49 | 0 | 1 | 1 | 3 | 10 |
| headline_words | 3,76 | 2,95 | 0 | 2 | 3 | 5 | 16 |
| pros_words | 13,91 | 14,24 | 0 | 6 | 8 | 16 | 87 |
| cons_words | 20,26 | 28,79 | 0 | 6 | 9 | 21 | 182 |
| year | 2018,76 | 3,24 | 2008 | 2016 | 2020 | 2021 | 2023 |

(3,07); у этой подоценки и наибольший разброс: четверть авторов ставит руководству 1 или 2. Средние подоценок рассчитаны после заполнения пропусков и несколько смещены к медиане. «Минусы» в среднем длиннее «плюсов» (20,3 слова против 13,9): о недостатках работодателя авторы пишут подробнее. Половина отзывов опубликована в 2020 году или позже.

Для категориальных признаков рассчитаны число категорий, мода и её доля в таблице 5. Признаки `firm` и `job_title` имеют очень высокую кардинальность, а именно даже самая частая конкретная должность, Sales Associate, встречается лишь в 1,62 % отзывов. Мнения о генеральном директоре и перспективах компании отсутствуют более чем у трети авторов.

Таблица 5 – Показатели категориальных признаков

| Признак | Категорий ($\approx$) | Мода | Доля моды, % |
|---|---|---|---|
| firm | 33 128 | Amazon | 1,49 |
| job_title | 458 094 | Unknown | 24,26 |
| employee_status | 3 | Current | 57,59 |
| recommend | 3 | Positive | 46,45 |
| ceo_approv | 4 | No opinion | 38,06 |
| outlook | 4 | No opinion | 35,55 |
| tenure_group | 7 | Unknown | 39,84 |

### 1.8 Визуализация распределений наиболее важных признаков

Для построения графиков подсчёт выполняется в Spark операциями `groupBy` и `agg`, а в pandas передаётся только результат из нескольких десятков строк. Для гистограмм номер интервала каждого значения также вычисляется в Spark.

**Общая оценка.** Распределение целевого признака `overall_rating` показано на рисунке 7. Чаще всего выставляется оценка 4 (29,79 %), затем 5 (27,07 %) и 3 (23,22 %); оценки 1 и 2 встречаются в 9,49 и 10,43 % отзывов. Таким образом, высокие оценки ставят 56,9 % авторов, а низкие — 19,9 %.

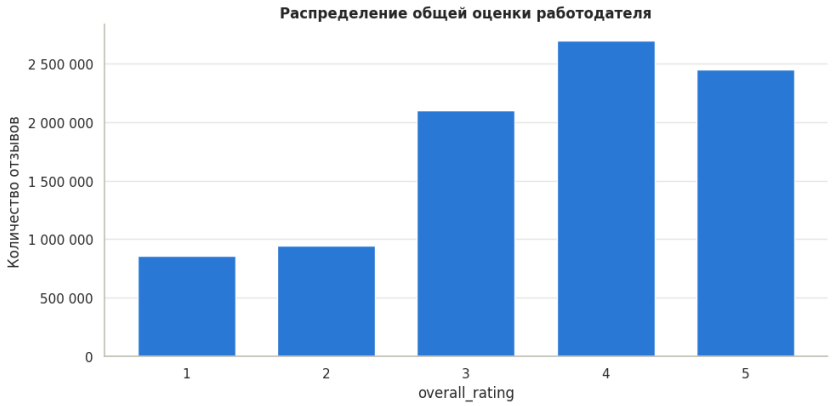



Рисунок 7 – Распределение общей оценки работодателя

**Динамика по годам** показана на рисунке 8. Число отзывов выросло с 34 983 в 2008 году до 1 799 845 в 2021 году; на 2021–2022 годы приходится 37,9 % датасета, а данные за 2023 год неполные. Средняя оценка выросла с 3,05 в 2010 году до 3,72 в 2022 году, особенно резко — между 2019 и 2020 годами (с 3,52 до 3,69). Причины роста по имеющимся данным установить нельзя. Возможными объяснениями являются изменения правил сбора отзывов, привлечение работодателями сотрудников к написанию отзывов и изменение состава компаний в выборке. Поэтому оценки разных лет непосредственно не сопоставимы.

**Мнения о компании.** Распределения мнений и средняя общая оценка в каждой категории приведены в таблице 6. Для рекомендации компании категория Mild отсутствует: на этот вопрос можно ответить только «да» или «нет».

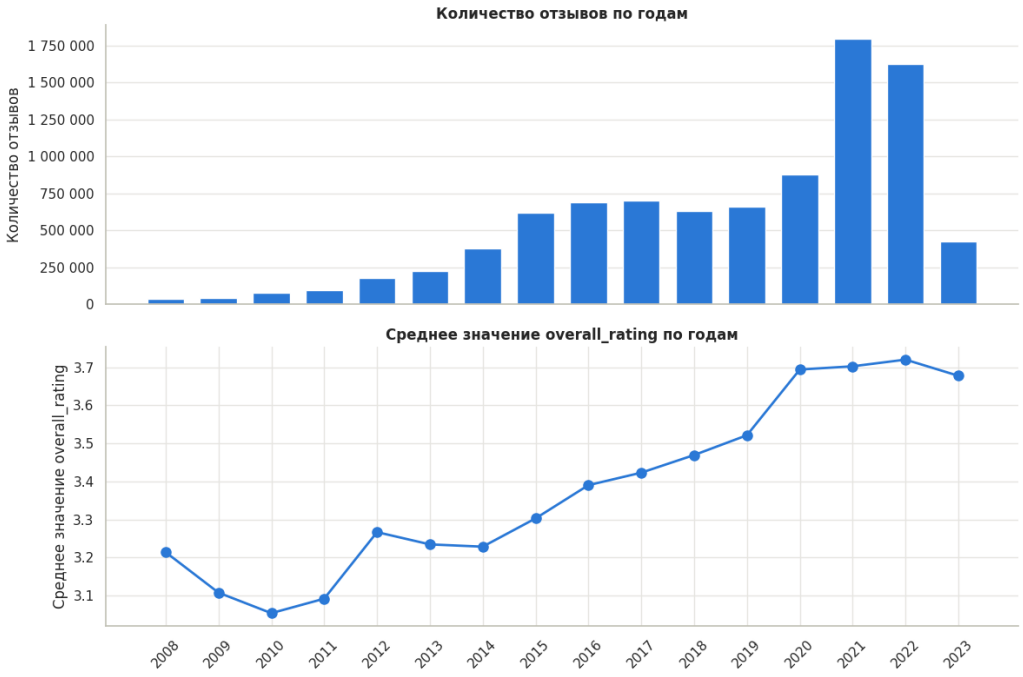



Рисунок 8 – Количество отзывов и средняя общая оценка по годам

Таблица 6 – Распределение мнений и средняя общая оценка по категориям

| Мнение | recommend | | ceo_approv | | outlook | |
|---|---|---|---|---|---|---|
| | Доля, % | Оценка | Доля, % | Оценка | Доля, % | Оценка |
| Positive | 46,45 | 4,22 | 32,46 | 4,17 | 34,30 | 4,23 |
| Mild | — | — | 19,22 | 3,12 | 16,80 | 3,15 |
| Negative | 24,73 | 2,14 | 10,26 | 2,04 | 13,35 | 2,08 |
| No opinion | 28,82 | 3,67 | 38,06 | 3,64 | 35,55 | 3,62 |

По всем трём признакам средняя оценка монотонно растёт от отрицательного мнения к положительному. Сильнее всего различаются группы по рекомендации: 4,22 у рекомендующих компанию против 2,14 у не рекомендующих, то есть разница составляет 2,08 балла. Авторы без мнения оценивают компанию на 3,6–3,7, близко к средней по датасету.

**Статус и стаж автора.** Текущие сотрудники (57,59 %) оценивают работодателя в среднем на 3,75, бывшие (42,41 %) — на 3,27. Разница почти в полбалла ожидаема, поскольку недовольные условиями работы чаще увольняются. Зависимость оценки от стажа приведена в таблице 7. На сайте стаж задаётся интервалами, поэтому, например, категория «более 1 года» означает стаж от 1 до 3 лет.

Таблица 7 – Средняя общая оценка в зависимости от стажа автора

| Стаж | Отзывов | Доля, % | Средняя оценка |
|---|---|---|---|
| менее 1 года | 1 190 066 | 13,14 | 3,510 |
| 1–3 года | 1 662 440 | 18,36 | 3,483 |
| 3–5 лет | 1 156 604 | 12,77 | 3,509 |
| 5–8 лет | 688 691 | 7,61 | 3,511 |
| 8–10 лет | 328 987 | 3,63 | 3,534 |
| более 10 лет | 420 747 | 4,65 | 3,579 |
| не указан | 3 607 549 | 39,84 | 3,600 |

Минимум оценки приходится на стаж 1–3 года, а с ростом стажа оценка повышается. Вероятное объяснение — эффект отбора: недовольные сотрудники уходят раньше. Различия между группами составляют около 0,1 балла, однако стандартная ошибка среднего даже для самой малочисленной группы равна $1{,}25/\sqrt{328\,987} \approx 0{,}002$. Поэтому различия статистически надёжны, но практически малы. Для больших данных это типично: на миллионах наблюдений значимыми оказываются даже очень малые эффекты, поэтому важно оценивать их величину. Наибольшая оценка в группе с неуказанным стажем подтверждает, что пропуски в этом признаке неслучайны.

## 1.9 Корреляционный анализ

Для оценки линейной связи между признаками использован коэффициент корреляции Пирсона

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}, \tag{2}$$

где $\bar{x}$ и $\bar{y}$ — средние значения признаков. В отличие от примера в методических материалах, где каждый коэффициент вычислялся отдельным заданием Spark, все коэффициенты матрицы вычисляются за один проход по данным:

```
pairs = [(a, b) for i, a in enumerate(columns)
         for b in columns[i + 1:]]
row = data.agg(
    *[F.corr(a, b).alias(f"{a}__{b}") for a, b in pairs]
).first()
```

Функция `corr` пропускает строки, в которых пусто хотя бы одно из двух значений. Это позволило вычислить корреляции оценок до заполнения пропусков, то есть только по реально выставленным оценкам (рисунок 9).

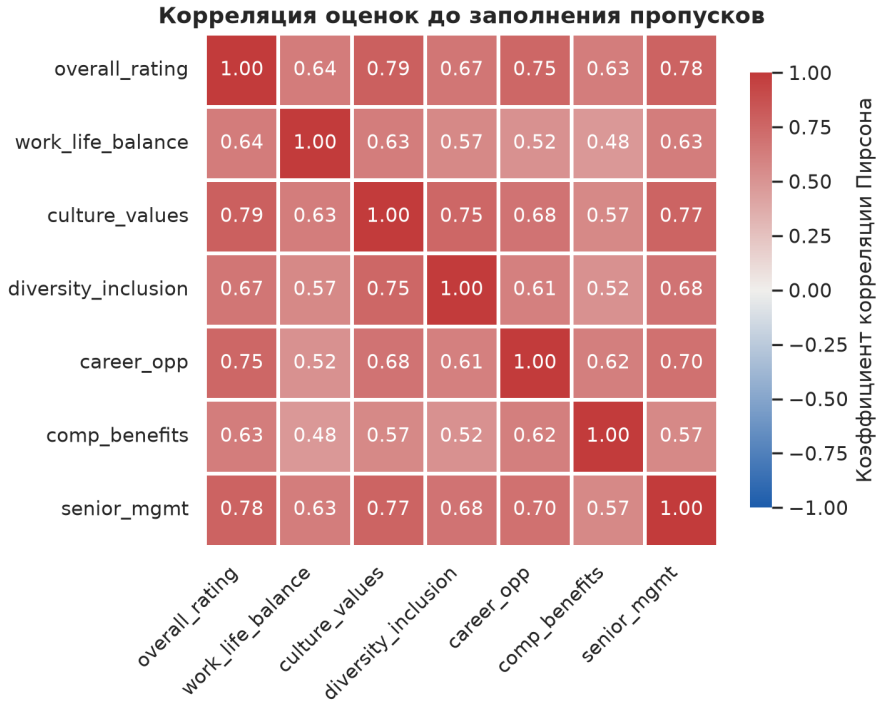



Рисунок 9 – Корреляция оценок до заполнения пропусков

Все коэффициенты положительны и лежат в диапазоне от 0,48 до 0,79, что объясняется одинаковой направленностью шкал и эффектом ореола (halo effect): довольный работодателем сотрудник склонен высоко оценивать все критерии. Сильнее всего с общей оценкой связаны культура и ценности (0,79), высшее руководство (0,78) и карьерные возможности (0,75), слабее — разнообразие и инклюзивность (0,67), баланс работы и жизни (0,64), зарплата и льготы (0,63). Самая слабая связь (0,48) наблюдается между балансом работы и жизни

и зарплатой: высокооплачиваемая работа нередко требует больше времени. Подоценка `diversity_inclusion` тесно связана с культурой (0,75) и во многом дублирует её.

Полученный порядок совпадает с результатами исследования Glassdoor [13], в котором регрессионным анализом оценивался вклад факторов в удовлетворённость сотрудников. Наибольший вклад в нём также внесли культура и ценности (22 %), высшее руководство (21 %) и карьерные возможности (19 %), а наименьший — баланс работы и жизни (13 %) и зарплата (12 %). Таким образом, разведочный анализ независимо воспроизвёл вывод опубликованного исследования: удовлетворённость определяется прежде всего культурой компании и руководством, а не зарплатой.

После заполнения пропусков корреляции подоценок с общей оценкой снизились на 0,06–0,09: для культуры и ценностей — с 0,787 до 0,700, для высшего руководства — с 0,775 до 0,702, для баланса работы и жизни — с 0,642 до 0,584. Причина в том, что у заполненных строк подоценка одинакова при любой общей оценке. Поэтому для оценки взаимосвязей следует опираться на коэффициенты, рассчитанные до заполнения.

Для полной корреляционной матрицы мнения закодированы как Positive = 1, Mild = 0, Negative = $-1$ (категории No opinion и Unknown в расчёте не участвуют), а статус сотрудника — как Current = 1, Former = 0. Константный признак `advice_words` в матрицу не включён, поскольку коэффициенты корреляции для него не определены. Матрица показана на рисунке 10, а корреляции признаков с общей оценкой — на рисунке 11.

Сильнее всего с общей оценкой связана рекомендация компании (0,76), затем подоценки руководства и культуры (по 0,70), карьерных возможностей (0,67), оценка перспектив (0,66) и одобрение генерального директора (0,61). Длина «минусов» отрицательно связана с общей оценкой ($-0{,}35$) и со всеми подоценками: недовольные авторы подробнее пишут о недостатках. Длина «плюсов» с оценкой не связана (0,03). Текущие сотрудники оценивают работодателя выше бывших (0,19). Год публикации слабо положительно связан с оценкой

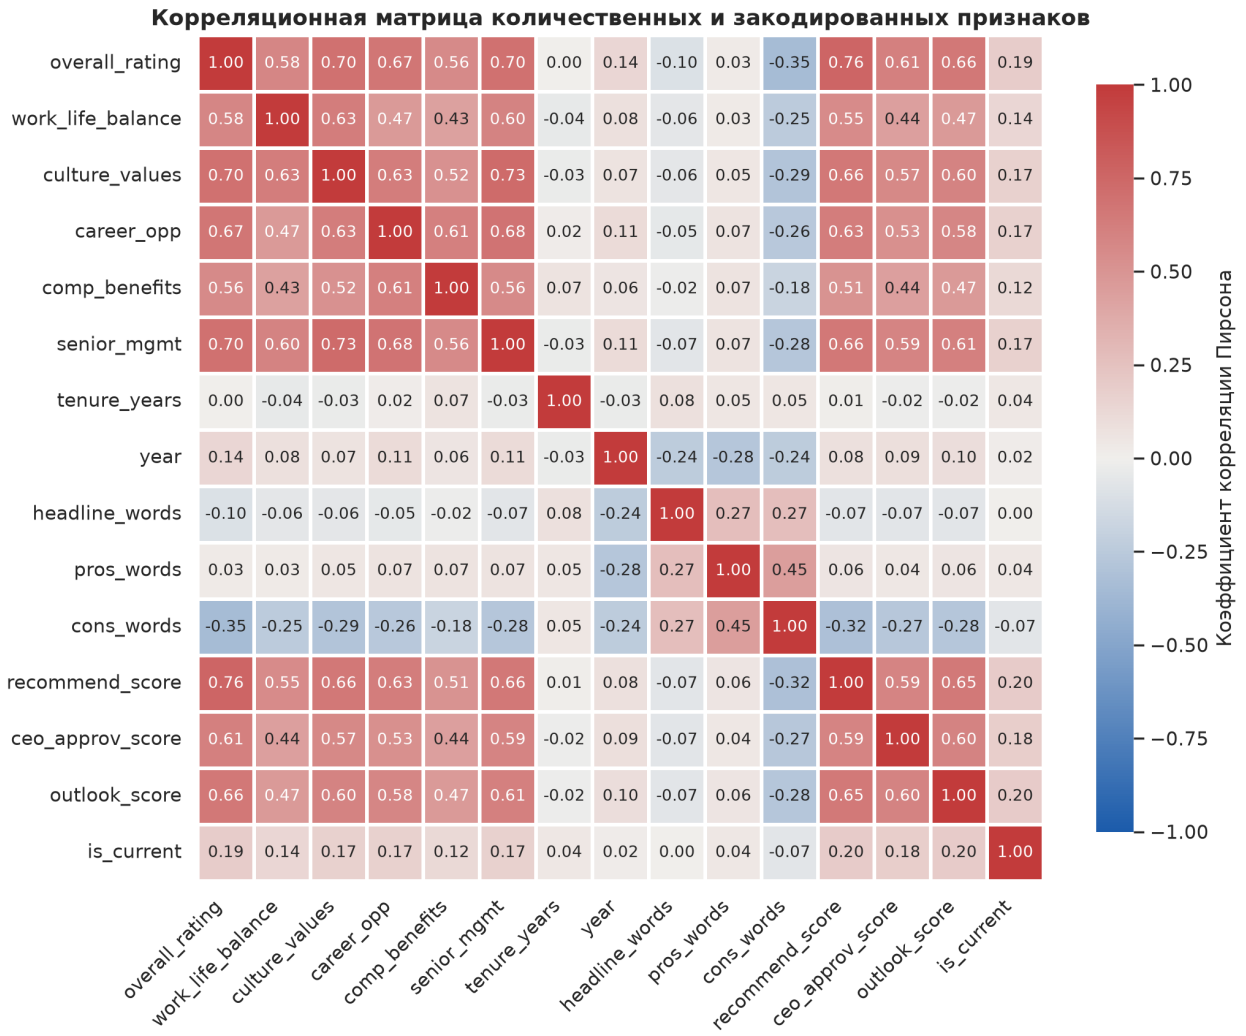



Рисунок 10 – Корреляционная матрица количественных и закодированных признаков

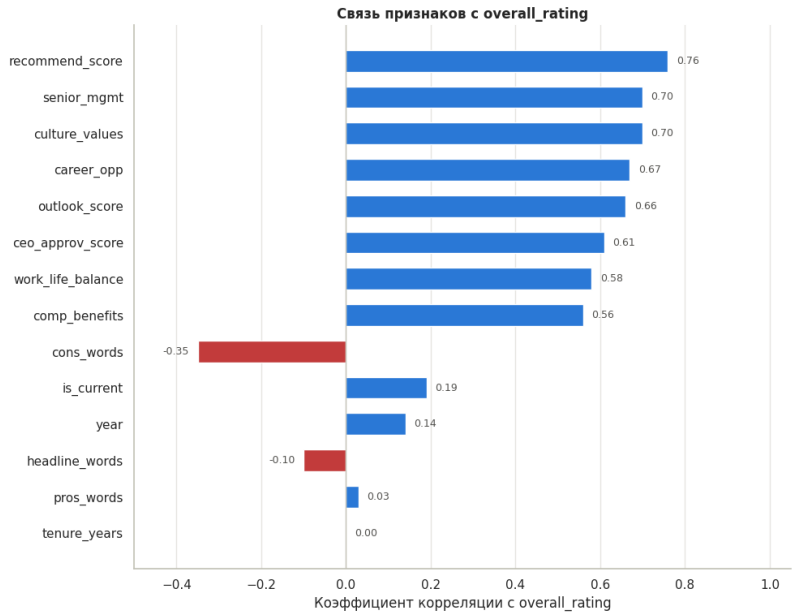



Рисунок 11 – Корреляция признаков с общей оценкой

(0,14) и отрицательно — с длиной текстов (от $-0{,}24$ до $-0{,}28$), то есть отзывы со временем становятся короче. Корреляция стажа с оценкой равна нулю, отчасти из-за заполнения 40 % значений медианой, поэтому выводы о стаже следует делать по таблице 7.

Следует учитывать, что коэффициент Пирсона измеряет только линейную связь, а для порядковых оценок можно дополнительно рассчитать ранговый коэффициент Спирмена (класс `Correlation` пакета `pyspark.ml.stat`); корреляция также не доказывает причинно-следственной связи.

## 1.10 Выводы

В главе средствами Apache Spark выполнен разведочный анализ датасета Glassdoor Job Reviews 2 объёмом 3,8 ГБ, содержащего 9,9 млн отзывов о 34 374 компаниях.

Были выявлены проблемы качества данных: 8,55 % строк оказались полными дубликатами, почти в каждой строке был пропуск. Пропуски во многом неслучайны: совет руководству практически не заполнен, оценка разнообразия и инклюзивности отсутствует у 66 % отзывов, стаж не указан у 40 %. Пропуски обработаны по единым правилам, причём показано, что заполнение медианой ослабляет корреляции на 0,06–0,09. Выбросы в длине текстов устранены ограничением по 99-му перцентилю без удаления строк. Показано также, что метод IQR неприменим механически к порядковым шкалам и к распределению отзывов по компаниям, где формальные выбросы являются достоверными данными.

Средняя общая оценка составляет 3,55 и выросла с 3,05 в 2010 году до 3,72 в 2022 году. Ниже всех оценивается высшее руководство, выше всех — корпоративная культура. Текущие сотрудники оценивают работодателя на 0,49 балла выше бывших. С общей оценкой сильнее всего связаны рекомендация компании, культура и руководство, слабее — баланс работы и жизни и зарплата, что совпадает с выводами исследования Glassdoor.

Итоговый набор данных из 9 055 084 строк и 20 признаков не содержит пропусков и сохранён в таблицу `glassdoor_reviews_processed` формата Iceberg. Он пригоден для построения моделей машинного обучения, например для регрессии (предсказание общей оценки) и бинарной классификации (предсказание рекомендации компании).

# ЗАКЛЮЧЕНИЕ

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ


1. *Tukey J. W.* Exploratory Data Analysis. — Reading, MA : Addison-Wesley, 1977. — 688 с.
2. Изучаем Spark: молниеносный анализ данных / Х. Карау [и др.]. — ДМК Пресс, 2015. — 304 с. — ил.
3. Официальный сайт Apache Spark. — 2022. — URL: https://spark.apache.org/ ; Дата обращения: 11.10.2026.
4. *Уайт Т.* Hadoop: Подробное руководство. — 3-е изд. — СПб. : Питер, 2013. — 672 с. — ил.
5. Exploratory Data Analysis with pySpark. — 2020. — URL: https://github.com/roshankoirala/pySpark_tutorial/blob/master/Exploratory_data_analysis_with_pySpark.ipynb ; Дата обращения: 11.10.2026.
6. *Feng W.* Data Exploration // Learning Apache Spark with Python. — 2021. — URL: https://runawayhorse001.github.io/LearningApacheSpark/exploration.html ; Дата обращения: 11.10.2026.
7. *Gauthier D.* Glassdoor Job Reviews 2: A large dataset of job reviews with textual features and numerical targets. — 2024. — URL: https://www.kaggle.com/datasets/davidgauthier/glassdoor-job-reviews-2 ; Дата обращения: 11.10.2026.
8. Apache Iceberg Documentation. — 2024. — URL: https://iceberg.apache.org/docs/latest/ ; Дата обращения: 11.10.2026.
9. Lakehouse: A New Generation of Open Platforms that Unify Data Warehousing and Advanced Analytics / М. Захария [и др.] // Conference on Innovative Data Systems Research. — 2021. — URL: https://www.cidrdb.org/cidr2021/papers/cidr2021_paper17.pdf ; Дата обращения: 11.10.2026.

10. *Heule S., Nunkesser M., Hall A.* HyperLogLog in Practice: Algorithmic Engineering of a State of The Art Cardinality Estimation Algorithm // Proceedings of the 16th International Conference on Extending Database Technology. — New York : ACM, 2013. — 683—692.

11. *Maurer R.* Glassdoor Introduces Diversity and Inclusion Ratings / SHRM. — 2020. — URL: https://www.shrm.org/topics-tools/news/talent-acquisition/glassdoor-introduces-diversity-inclusion-ratings ; Дата обращения: 11.10.2026.

12. *Greenwald M., Khanna S.* Space-Efficient Online Computation of Quantile Summaries // Proceedings of the 2001 ACM SIGMOD International Conference on Management of Data. — New York : ACM, 2001. — 58—66.

13. *Stansell A.* Which Workplace Factors Drive Employee Satisfaction Around the World? / Glassdoor Economic Research. — 2019. — URL: https://www.glassdoor.com/blog/employee-satisfaction-drivers/ ; Дата обращения: 11.10.2026.